



来看一个例子。


以中证 500 的成分股为选股池、2010 年 1 月到 2018 年 10 月为回测期，评价不同的选股因子 —— 以该因子选出的前 50 支股票构建纯多头的投资组合的最终净值评价因子的效果。当测试了 20 个不同的因子后，最优秀的因子的净值为 2.29（同期中证 500 指数净值仅为 1.06）。这 20 个因子的净值如下图所示（紫色加粗的是最好的那个）。



如果把测试因子的个数从 20 个上升至 50 个，选股效果进一步提升，最好因子的净值从 2.29 上升至 2.40。下图是 50 个因子（包括最开始的 20 个）的选股效果，紫色加粗曲线依然为前 20 个因子中最好的、红色加粗曲线为这 50 个因子中最好的。




最后，我们把测试的个数上升至 100（这是一个任何量化选股报告中都会轻易突破的因子个数）。这 100 个因子中（包括之前 50 个），最好的因子的净值为 2.43，在前 50 个因子的基础上进一步提高了。下图中黑色加粗曲线代表了全部 100 个因子中最好的那个的选股净值。



考虑到这些因子之间不是完全相关，如果我们把这三个因子结合起来再配合更复杂的交易算法，一定能在回测期内获得更好的选股效果。但是，**如果仅仅因为最终的策略中只用了三个因子就认为没有过拟合，那就大错特错了，因为在发现这三个因子的背后是 97 次失败的尝试。**

EXHIBIT 1

Long-Short Market-Neutral Strategy Based on NYSE Stocks, January 1963 to December 2015



Notes: Gray areas denote NBER recessions. Strategy returns scaled to match S&P 500 T-bill volatility during this period.

Source: Campbell Harvey, using data from CRSP.

出处: Arnott, Harvey, and Markowitz (2019)

上图是某针对美股的选股策略在长达 50 年的回测内的净值曲线。该策略采用多空对冲、市值中性的方法构建。该策略表现出了五大优秀量化策略的必要不充分（呵呵）特征：

1. 因子计算的方法在回测期内完全一致，没有任何变化；
2. 该策略的表现在近期并没有变差的迹象，说明在该因子上并没有发生“拥挤”；
3. 该因子穿越牛熊，在金融危机时代甚至出现了上涨（在可以做空的假设下）；
4. 该因子和其他主流因子（包括市场、Size、Value、Momentum 等）的相关度极低；
5. 该因子的年换手率仅为 10%，交易成本可以忽略不计。

没错，它正是 data mining 的产物。该因子的构建完全没有使用任何基本面或者交易数据，而仅仅依赖美股上市公司股票代码上的字母。比如苹果公司的股票代码是 AAPL^Q，该代码上的第 1 至 4 位上的字母分别为 A、A、P 以及 L。该因子的构建方法是做多股票代码第三位字母为 S 的股票、做空股票代码第三位字母为 U 的股票（记为 S(3) - U(3)）。

在实验中，考虑股票代码的前 3 位字母；考虑到全部可能的 26 个字母，以及每个字母可以出现在多、空两头，因此实验中有成千上万种组合方式。而 S(3) - U(3) 这种组合正是从这些组合中脱颖而出的、具备了上述五大优秀特征的、仅仅来自 data mining 的虚假策略。

Significant level: α



Hypo:

H_0 : not significant

H_1 : significant


Error:

Type I False positive 假阳/假显著

$$\alpha = P(\text{接受 Type I error 发生的概率}) \approx 5\% \text{ or } 1\%$$

Type II False Negative 假阴/漏掉显著

$$\beta = P(\text{Type II 错误发生的概率})$$



⊗ 金融世界 → 厌恶风险 → 关注 α 的控制 (类似的, 生物医药统计)

⊗ 调整 α 只影响对错误的容忍
不反应对假设的真实性影响

⊗ 增加样本量 $\Rightarrow$ 降低 P.V. 的 Var $\Rightarrow$ 同时降低两类错误

FWER: Family-wise Error Rate

$$= P(\text{at least one false positive})$$

$$= P(N \text{ 个因子/试验中至少有一个是假因子})$$

$$= 1 - P(0) = 1 - (1 - \alpha)^N$$

$$N = 1: \text{FWER} \approx 5\%$$

$$N = 20: \text{FWER} \approx 64\%$$

$$N = 100: \text{FWER} \approx 99.4\%$$

$$= 1 - P(0) = 1 - (1 - \alpha)$$

$$N = 1: \text{FWER} \approx 5\%$$

$$N = 20: \text{FWER} \approx 64\%$$

$$N = 100: \text{FWER} \approx 99.4\%$$

Non - Normality :

Model Assumption & Empirical Distribution 差距

e.g. 对 Normal 分布, $P(\text{out of } \pm 3\sigma) = 0.3\%$

对 肥尾 分布, $P(\text{out of } \pm 3\sigma) \gg \uparrow$

$\Rightarrow$ Type I error $\uparrow$

	H_0 接受	H_0 拒绝	总和
H_0 真	T_0	F_1	k_0
H_0 假	F_0	T_1	k_1
	$k - L$	$L = F_1 + T_1$	k

$\Rightarrow$ k 个因子

$\rightarrow \begin{cases} k_0, H_0 \text{ 真, 不显著} \\ k_1, H_0 \text{ 假, 显著} \end{cases}$

$\rightarrow \begin{cases} L \text{ 个 认为显著} \\ k - L \text{ 个 认为不显著} \end{cases}$

$$\text{FWER} = P(\text{nb}(F_i > 1) \leq d_s)$$

Bonktesting (Harvey)

Core Idea:

Haircut for Significance Threshold

$N \uparrow \rightarrow$ Threshold $\uparrow$
P-value $\downarrow$

Get some haircut method from Bio Stats

F(1) Bonferroni Correction: $p_i^B = \min\{kp_i, 1\} \quad i=1, \dots, k$

$$\alpha_{adj} = \alpha / N$$

问题: $N \uparrow \rightarrow \alpha_{adj} \downarrow$

$P(\text{Type II error}) \uparrow$

找不到有效的

F(2) Holm's method $p_i^H = \min\{\max_{j \leq i} \{ (k-j+1)p_j \}, 1\} \quad i=1, \dots, k$

F(3) BH method

控制 FDR: False Discovery Rate = $\frac{\text{假设因子}}{\text{总的}}$

$$= \frac{\text{Type I error}}{\text{总的}} = E\left[\frac{N_r}{k}\right]$$

$$= E\left[\frac{r}{k}\right] \leq \delta$$

⊗ 局限:

① 过于统计, 只考虑不同策略的 P-value 调整

很多方法要求独立

但很多调参数的因子高度相关

最后变成统计数值调整的 Trap

② 对分布有要求

③ 只能是 1 个因子, 不是多因子的场景

Framework:

非线性关系

① $SR \rightarrow p\text{-value}$


$$p^S = \text{Prob}(|r| > SR \cdot \sqrt{T})$$

② 对 P-value haircut

$$p^S \rightarrow p^M$$

③ $p^M = \text{Prob}(|r| > HSR \cdot \sqrt{T})$

$$\rightarrow HSR = \frac{1}{\sqrt{T}} \cdot t_{\text{cor}}^{-1}(1 - p^{\frac{k}{2}})$$




DSR (Lopez)

均量:

不同策略类型后, 用 optimized 参数

⇒ 假设:

不同参数下, 策略的 Sharpe $\sim N(\mu, \sigma^2)$



N 组参数中:

$$E[SR_{max}] \approx E[SR] + \sqrt{V[SR]} \left((1-\gamma)Z^{-1}\left[1-\frac{1}{N}\right] + \gamma Z^{-1}\left[1-\frac{1}{N}e^{-1}\right] \right)$$


其中:

γ : Euler-M constant ≈ 0.5772

Z : 正态 CDF

$$\Rightarrow \begin{matrix} N \uparrow \\ V[SR] \uparrow \end{matrix} \rightarrow SR_{max} \uparrow$$

下图显示了当 $E[SR] = 0$ 时, 仅仅增加 N 和 $V[SR]$ 就可以逐渐提升最优夏普率。增大 N 对应着在回测中增加 number of tests, 增大 $V[SR]$ 对应着完全不考虑业务依据而漫无目的的扩大参数的取值范围。这些都是造成拟合的原因。



DSR

Our earlier analysis has shown a second source of inflation, caused by selection bias. Both sources of inflation, when conflated, can lead to extremely high estimated values $\hat{SR}$, even when the true SR may be null. In this paper we propose a *Deflated Sharpe Ratio* (DSR) statistic that corrects for both sources of $\hat{SR}$ inflation, defined as:

$$\underline{DSR} \equiv \underline{PSR}(\hat{SR}_0) = Z \left[\frac{(\hat{SR} - \hat{SR}_0)\sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \hat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \hat{SR}^2}} \right] \quad (2)$$

$E[\max\{\hat{SR}_n\}]$

where $\hat{SR}_0 = \sqrt{V[\{\hat{SR}_n\}]} \left((1-\gamma)Z^{-1}\left[1-\frac{1}{N}\right] + \gamma Z^{-1}\left[1-\frac{1}{N}e^{-1}\right] \right)$, $V[\{\hat{SR}_n\}]$ is the variance across the trials' estimated SR and N is the number of independent trials. We also use information concerning the selected strategy: $\hat{SR}$ is its estimated SR, T is the sample length, $\hat{\gamma}_3$ is the skewness of the returns distribution and $\hat{\gamma}_4$ is the kurtosis of the returns distribution for the selected strategy. Z is the cumulative function of the standard Normal distribution.

CPF

e.g. pnl $\rightarrow$ return, T , N , Variance, skew, kurt

$\Rightarrow \hat{DSR}$ 与 SR 比较

Regression (Harvey)

15/7, predictive Reg

panel Reg

Fama-MacBeth Reg

通过因变量 Y 和解释变量 X 之间的正交化处理剔除 X 能够解释 Y 的部分，从而构建 null hypothesis: X 无法解释 Y ;

↓

使用每个正交化后的因子 X 解释 Y ，找出它们中最显著的，这个显著性全部来自运气的成分（因为正交化保证了 null hypothesis 是正交化后 X 无法解释 Y ）;

↓

通过 Bootstrap 采样进行大量实验就可以得到仅凭运气得到的显著性的经验分布，这就是在 null hypothesis（即仅靠运气）下显著性的分布;

↓

如果来自真实数据中最显著的那个因子的显著性在这个分布的 95%（或 90%、99%）分位数之上，那就说明即便排除了足够好的运气

eg. $100 \times X \rightarrow Y, T=500$

①: $x_i \sim Y \quad i=1, \dots, 500$
 $\rightarrow \varepsilon_i \quad i=1, \dots, 500 \quad (\varepsilon_i \perp Y)$

H_0 : 残差对 Y 没有预测性

②:

Y	ε_1	$\dots$	ε_{500}
y_1			
$\vdots$			
y_{500}			

 按行做放回的 Bootstrap
 得到新的 500×501 Matrix

101

③ 对 Bootstrap Matrix

每次记录:
 在 Bootstrapped Data 上的 max t-stat

④ 重复 10000 次.

得到 10000 个 t-stat

$\Rightarrow$ 在 H_0 假设下，得到一个分布:

完全没有用的因子，纯靠运气，max t-stat 分布

$\Rightarrow$ 可能会出现: 

说明，t 筛选的标准为 3

⑤ 以新的分布和 threshold 检验 $Y \sim X_i, i=1, \dots, 100$

选择出因子 X_k

⑥ 剔除: Y 中的 $X_k \quad X_k \sim Y \rightarrow 0Y$
 X_i 中的 $X_k \quad X_i \sim Y \rightarrow 0X_i$

$\Rightarrow 0Y \rightarrow Y \Rightarrow$

Y	$0x_1$	$\dots$	$0x_n$

③ 对 Bootstrap Matrix

每次记录:

在 Bootstrapped Data 上的 max t-stat


④ 重复 10000 次.

得到 10000 个 t-stat

⇒ 在 H_0 假设下, 得到一个分布:

完全没有用的因子, 纯靠运气, max t-stat 分布

⇒ 可能会发现:



说明, t 筛选的标准为 3

⑤ 以新的分布和 threshold 检验 $Y \sim X_i, i=1 \dots 100$


选择出因子 X_k

⑥ 剔除: Y 中的 X_k $X_k \sim Y \rightarrow 0Y$

X_i 中的 X_k $X_i \sim Y \rightarrow 0X_i$

⇒ $0Y \rightarrow Y$

$0X_i \rightarrow X_i$



⑦ Stop: 当无因子可过线

⑧ 一点缺陷 / 改进 / 想法

①: 不断重复挑选因子后, p-value 会定个, 是否需要动态调整 threshold

②: 更适用高相关同类因子 / RoF 等

S&P Capital IQ

③: Alpha Factor Library 做 Datasets

> 600 Td

⑨ Bootstrap 拓展到的场景

Noruy - Max

Selection bias

Overfitting bias

当多因子选因子时:

n 选 1 (依据某指标) → selection bias


n 选 n → overfitting bias

n 选 k → selection bias
overfitting bias

实证中的回溯期从 2010 年 1 月到 2019 年 1 月，考察 n 个随机因子的选股能力。具体的：

1. 对于每一个因子，在每月末，随机生成 500 支成分股在该因子上的取值并从高到低排列，选择取值最高的 10% 做多、取值最低的 10% 做空，以该多空组合的收益率作为该期因子的收益率；
2. 计算回溯期内每个因子的 t -statistic，如果某个因子的 t -statistic 为负，则把该随机因子反过来使用；
3. 按照每个随机因子 t -statistic 绝对值的大小，挑选绝对值最大的 k ($k \leq n$) 个因子，并按照等权或者正比于它们 t -statistics 的绝对值大小配置因子；
4. 以最终多个因子的配置结果作为最终的选股结果，计算该策略在整个回溯期内的 t -statistic；
5. 上述 1 - 4 步完成了 n 选 k (当 $k = 1$ 和 n 时，问题分别变为 n 选 1 和 n 选 n) 的一次实验。为了得到 n 选 k 问题中 t -statistic 的经验分布并计算 5% 显著性水平下的 t -statistic 的阈值，对于每一组 n 和 k ，将上述 4 步进行 5000 次仿真，从而计算 t -statistic 的阈值。


举个例子。下图是当 $n = 20$, $k = 3$ (即从 20 个随机因子中选出样本内 t -statistic 绝对值最大的 3 个，并按 t -statistic 绝对值大小配置) 时，5000 次仿真得到的该策略的 t -statistic 的经验分布，其均值为 3.2，其 5% 显著性水平下对应的 t -statistic (即该分布中 95% 分位数) 高达 4.16。



该结果表明，如果我们从 20 个源于业务逻辑 (或者很多人乐此不疲的 data mining) 的因子中选择 3 个最好的来选股时，该策略的 t -statistic 要超过 4.16 才能认为这 3 个因子的选股效果不仅仅是运气。


接下来看看不同 n 和 k 的取值下，5% 显著性水平对应的 t -statistic 的阈值的情况。下图比较了不同 n 取值下， n 选 1 和 n 选 n 两种极端情况 —— n 选 1 代表仅有 selection bias； n 选 n 代表仅有 overfitting bias。下图传递出以下信息：

1. 随着考察的随机因子个数 (n) 的增加，策略 t -statistic 的阈值逐渐递增；
2. 选 n 个因子比选 1 个因子有更高的阈值；按样本内表现配置比等权配置有更高的阈值；它们说明 overfitting bias 比 selection bias 更容易在样本内产生过拟合。



再来看看更一般的 n 选 k 的情况。下图显示了 $n = 10, 20, 40$ 和 100 时，不同 k 取值下的选股策略的 t -statistic 阈值。在一般的投资实务中，尝试 100 甚至几百个因子并选择其中某些好的是十分常见的。从该实证结果中可以观察到：

1. 随着 n 和 k 的增加，对于按照随机因子 t -statistic 绝对值赋权配置的策略，它们的 t -statistic 阈值递增；
2. 随着 n 的增加，等权配置和按因子样本内表现配置的效果越来越接近；
3. 对于等权配置因子的情况，能够观察到策略的效果并不随 k 递增；比如当 $n = 10$ 时， t -statistic 的阈值随 k 先增大后减小。



上述实证结果中，最有趣的大概是第三条。对于等权配置的情况，在一开始，使用更多的因子可以降低策略的波动率，从而提升 t -statistic 的阈值；而一旦因子个数超过最优值，越来越多排名靠后的因子被选入，它们会降低策略的收益率，从而降低 t -statistic 的阈值。这是在因子投资实务中需要考虑的问题。

从图中可以看到，对于实证中考察的最极端情况，即“从 100 个因子选 10 个最好的”，仅仅靠运气，以随机因子构建的策略在中证 500 成分股的样本内回溯中就能取得高达 7 以上的 t -statistic 阈值。Data mining 造成的 selection bias 和 overfitting bias 不容小视。

(2017)

Lopez & Bailey : PBO

⊕ Def of PBO

$$PBO = \text{Prob} (SR_{005}(n^*) < ME[SR_{005}])$$

共 N 组不同参数, n^* : IS 表现最好的参数 $SR_{005}(n)$: 第 n 组参数在 005 表现 $ME[SR_{005}]$: N 组参数在 005 的表现中位数

⊕ Framework: CSCV

第一步: 首先在回测期内使用 N 组参数各自跑策略, 得到每组参数在 T 期的收益率序列, 以此构建一个 $T \times N$ 阶矩阵 M , M 的每一列代表为某组参数 n 的 T 期收益率序列。

第二步: 将 M 矩阵按行划分成 S 个互不相交的 $T/S \times N$ 阶子矩阵。例如, 假设原始的 $T = 1000$ 期, 则可以取 $S = 10$, 并把 M 划分成 10 个子集, 每个子集为 $100 \times N$ 阶矩阵。

第三步: 从全部 S 个子矩阵中, 取出 $S/2$ 个, 令 C_s 代表所有可能的组合。举例来说, 如果 $S = 10$, 则从 10 个子集中取出 5 个, 一共有 252 种组合方法, C_s 就是这 252 种组合的合集。

第四步: 对 C_s 中的每一个特定组合 c , 进行如下操作:

- 4a. 将 c 包含的子矩阵拼在一起构成训练集 J , 它是一个 $S/2 \times N$ 阶矩阵;
- 4b. 将全部 S 个子矩阵中不被 c 包含的子矩阵 (即 c 的补集) 拼在一起构成测试集 J_c , 它也是一个 $S/2 \times N$ 阶矩阵;
- 4c. 在训练集 J 矩阵中, 计算每一列收益率序列的夏普率, 它们之中夏普率最大的对应的策略 n^* 为样本内的最优策略;
- 4d. 在对应的测试集 J_c 矩阵中, 计算每一列收益率序列的夏普率, 并求出 n^* 这组参数在样本外的相对排名 w , w 的取值在 0 到 1 之间, 1 意味着样本内最优的策略 n^* 在样本外同样最优。
- 4e. 定义 logit 变量如下:

$$\lambda = \ln \frac{w}{1-w}$$

由定义可知, 如果 n^* 在样本外的表现等于所有参数在样本外夏普率的中位数, 则 $w = 0.5$, 而 $\lambda = 0$ 。


第五步: 上一步后会得到 λ 的经验分布 $f(\lambda)$, 由此就可以求出 PBO:

$$PBO = \int_{-\infty}^0 f(\lambda) d\lambda$$

$$\lambda < 0 \Leftrightarrow \frac{w}{1-w} < 1$$

$$w < \frac{1}{2}$$

$(-\infty, 0)$: n^* 在 005 中输给中位数
 $\Rightarrow$ (可以调积分区域)



⊕ CSCV 类似方法的一些问题: 金融时序路径依赖

e.g. (2011)

④ CSCV 类似方法的一些问题：金融时序路径依赖


e.g. (石川)

一个例子

在《从 CTA 趋势策略的表现看量化投资面临的挑战》一文中，我们使用 15 种商品期货的指数定性分析了过去 5 年趋势追踪策略的表现。该文的实证采用的是最简单的双均线策略——短周期均线上穿长周期均线策略时做多；短周期均线下穿长周期均线时做空。长、短周期就是策略的两个待优化的参数（由 LW 和 SW 表示）。下面就使用本文介绍的框架来计算优化这两个参数时的过拟合概率。

在回测中，令短周期均线参数 SW 的取值范围为 1 到 20、长周期均线参数 LW 的取值范围是 SW + 1 到 50，步长均为 1，因此一共有 790 组参数（ $N = 790$ ）。令回测长度为 1000 个交易日。使用这 790 组参数分别进行回测，得到每组参数下策略在这 1000 个交易日内的收益率序列，从而构建原始的 M 矩阵（ 1000×790 阶）。


使用第四节介绍的 CSCV 框架分析 M 矩阵，假设分析中 $S = 10$ ，因此一共有 252 种（10 选 5）回测 + 测试集的配对。在计算 PBO 之前我们先来做一个实验。对于每一种配对，求出样本内最优参数的夏普率和该组参数在样本外的夏普率，这两个夏普率便构成一个样本点，因此一共有 252 个样本点。这 252 个点的散点图如下（其中红线为回归得到的线性关系）：



为了减弱路径依赖对评判趋势策略过拟合程度的影响，我们对 CSCV 进行适当的改进，引入一定的随机性。


在 CSCV 的第三、四步，不是考虑所有可能的组合，而是随机的构建训练集和测试集。具体的，将长度 1000 的回测期分成 50 个长度为 20 个交易日的子集。从这 50 个子集中，随机选出 13 个作为测试集、13 个作为训练集（13 这个数并没有什么特殊的含义），因此训练集和测试集的长度各为 260 个交易日。将上述过程重复 250 次，得到 250 个训练集、测试集配对，然后计算 λ 的经验分布 $f(\lambda)$ 以及 PBO。

引入随机性后，再次画出样本内最优参数的夏普率和它在样本外的夏普率的散点图（下图），原始结果中不正常的线性上限消失了。回归方程的斜率是 -0.49 ，说明样本内、外的夏普率之间存在负相关性。



样本内最优参数的夏普率和其在样本外的夏普率之间的相关系数为 -0.36 ；上述回归直线的斜率为负也说明了这种负相关关系。这说明，对于这个双均线趋势策略，样本内最好的参数倾向于在样本外有更差的表现。


在进一步使用 CSCV 计算 PBO 之前，我们观察到上图中存在一些不正常的现象——这些散点的分布区域的上限似乎近似地坐落在一条直线上（下图），意味着这些点对应的训练集和测试集的夏普率之和大致相同。



出现这种现象的原因是趋势策略非常依赖价格序列的路径。在整个 1000 个交易日的回测期内，趋势策略挣钱的表现集中在某些特定的时间。当我们采用 CSCV 将这 1000 个交易日划分成 252 个长度各为 500 的训练集、测试集配对时，这其中有相当一部分的训练集都包含了趋势策略最赚钱的那些特定时间，使得这些训练集中的最优参数相同。

对于这些训练集、测试集配对，它们的 n^* 相同，因此它们在样本内、外全部 1000 个交易日内收益率的均值都是来自策略 n^* ，即均值相同。虽然这些配对中的训练集和测试集不尽相同，但由于收益率的波动率在整个回测期内较为稳定，因此训练集和测试集内的夏普率之和近似的等于这两个序列中收益率均值之和。综合以上两点就能够解释为什么这些配对的样本内、外夏普率之和非常接近。由于它们对应的 n^* 恰好又是整段回测期内效果最好的参数，因此这些配对的散点构成了上图中散点分布中不正常的线性上限。

此外， λ 的经验分布 $f(\lambda)$ 如下图所示：



通过 $f(\lambda)$ 求出 $PBO = 0.572$ ——在使用双均线构建趋势追踪策略时，回测中过拟合的概率高达 0.572。一个靠谱的策略的 PBO 不应该这么高。因此，在使用双均线构建趋势策略时必须格外小心。